KuaiRand 第一周技术报告

Pure 数据集上的双塔召回基线

实验日期：2026 年10 月12 日　数据协议：completion-time-v1

核心结论：本报告只呈现最新的内容属性实验：数据审计、两组训练、向量导出、精确检索和受控GPU 恢复验证已经跑通。热门基线Recall@100 为27.078%，Basic 为2.504%，Enhanced 为2.262%。工程产物齐全，但当前双塔尚未体现个性化收益。

1　任务与数据范围

我们研究的是**长观看导向的候选召回**：给定某个用户在某个时间点的上下文，从当时符合资格的视频中推荐前100 个。模型输出排序分数，不输出经过校准的长观看概率。

监督标签直接使用官方`long_view`。视频不超过18 秒时，观看达到视频时长算正反馈；更长的视频观看达到18 秒算正反馈。训练只使用`is_random=0` 且`long_view=1` 的记录。**“随机”描述平台如何选视频，不描述用户如何观看。**非随机曝光（`is_random=0`）是平台原推荐系统挑选视频并展示给用户；随机曝光（`is_random=1`）是数据采集实验中，平台从规定候选池随机选视频展示给用户。随机曝光不是我们训练时打乱样本，也不是随机划分训练集。

1.1　Pure 与完整数据集有什么区别?

官方版本	用户数	视频规模	保留方式
KuaiRand-27K	27,285	约3,204 万	完整发布版本，保留这些用户在采集期的广泛行为记录。
KuaiRand-1K	1,000	约437 万	从27K 随机抽取用户，保留这些用户的相关记录。
KuaiRand-Pure	27,285	7,583	只保留固定候选池内视频的交互；删除池外视频记录。

表 1: 官方版本口径，区别于下表中我们切分、去重后的实验规模。

Pure 不是“更干净的全量数据”，也不是只含随机曝光：它同时含常规曝光与随机曝光。官方常规曝光部分涉及7,551 个视频，完整候选池为7,583 个。**它主要缩减视频范围，而非用户范围；用户行为序列因此不完整。**本阶段用它验证闭环，不能据此判断长序列建模在完整27K 上的效果。官方建议严格序列研究优先使用27K 或1K。[1]

1.2　本次实验实际规模

窗口	非随机曝光	长观看正反馈	正反馈比例	用户数
历史预热	886,326	297,920	33.61%	25,185
训练	363,643	124,255	34.17%	25,769
验证	94,578	30,589	32.34%	20,565

表 2: 精确整行去重后的规模；候选库共7,583 个视频。测试集未参与本报告。

历史预热：4 月15 日正式训练开始前的记录只用于构建用户已有的长观看历史，不作为优化器更新样本，也不计入热门基线。这样第一条训练请求也可以带上用户此前已完成的观看，而非把所有用户都当成空历史。Enhanced 最多使用最近50 条已可用的正反馈；Basic 不使用这段历史。这是数据历史的准备，不是学习率warmup。

训练期正反馈集中在热门视频：前100 个视频占训练正反馈的26.83%。这使热门计数成为必须比较的基线。

2 数据处理与实际输入

2.1 时间协议与处理

以UTC 时间戳切分：4 月15 日前预热；4 月15 日至29 日前训练；4 月29 日至5 月4 日前验证，测试封存。去除20,624 条完全相同的原始记录，保留真实重复观看。原始日期与时间戳存在不一致，不用原始日期切分。

历史要求$t_{\text{request}} + \texttt{play_time_ms} < t_{\text{current}}$，同毫秒完成的反馈不可用。这修正了1,038 条历史；播放结束只是反馈可用时间的代理。词表在训练范围拟合、验证时冻结；未知类别索引为0。

2.2 用户塔与物品塔分别接收什么?

输入字段	实际原始值示例	编码与维度
用户塔：前三项两组共用，历史两项仅Enhanced 使用		
`user_id`	20853、8286	用户词表索引，32 维embedding；未知用户索引0。
`tab`	0、1、4；范围0–14	场景类别索引，8 维embedding。
`time_ms`	1649475963278 毫秒	UTC 日、周周期的正弦与余弦，共4 维。
`history_item_ids`	最多50 次已可用的视频ID	经共享物品塔得到$[B, 50, 64]$，按mask 求均值得$[B, 64]$。
`history_mask`	长度50 的有效位标记	padding 为-1，不参与均值；空历史为零向量。不作为额外数值拼接。
物品塔：两组均使用以下11 个字段		
`item_id`	0、1、2	冻结词表索引；8 维embedding。
`author_id`	7349781、2103883	作者类别索引；8 维embedding。
`video_type`	NORMAL、AD	视频类型；8 维embedding。
`upload_type`	LongImport	上传方式；8 维embedding。
`music_id`	9155697141	音乐类别索引；8 维embedding。
`music_type`	9、4、8	音乐类型；8 维embedding。
`tag`	39、2、1	沿用原预处理，只保留首个标签；8 维embedding。
`video_duration`	87433 毫秒	数值缺失用训练物品中位数填补，再标准化；1 维。
`server_width`	720、960 像素	同上；1 维。
`server_height`	1280、720 像素	同上；1 维。
`upload_day`	上传日期2022-04-10 → 1 天	相对训练物品最早上传日2022-04-09 的天数，标准化；1 维。

表 3: 七个类别embedding 共56 维，拼接四个数值共60 维；最终物品向量为64 维。

类别缺失作为独立类别，未见类别使用索引0；数值按训练物品拟合$z = (x - \mu)/\sigma$，验证与候选库复用冻结参数。例如时长87433 毫秒编码约为-0.194，宽720 编码约为-0.558，上传1 天编码约为0.285。

请求时间示例编码约为$(0.834, 0.552, -0.997, -0.083)$。

两组的区别：Basic 的用户输入为$32 + 8 + 4 = 44$ 维；Enhanced 再拼接64 维平均历史，成为108 维。两组物品输入均为60 维；Enhanced 的历史也复用包含全部属性的物品塔。

时间有效性：时长与训练、验证的154,273 条可比较正反馈完全一致；其余发布属性采用固定内容假设，缺少历史版本佐证。当前可见状态、整月行为统计与无时间版本的用户统计排除；标签、随机标记、请求ID 和split 不作输入。

3 模型与损失

3.1 两组架构

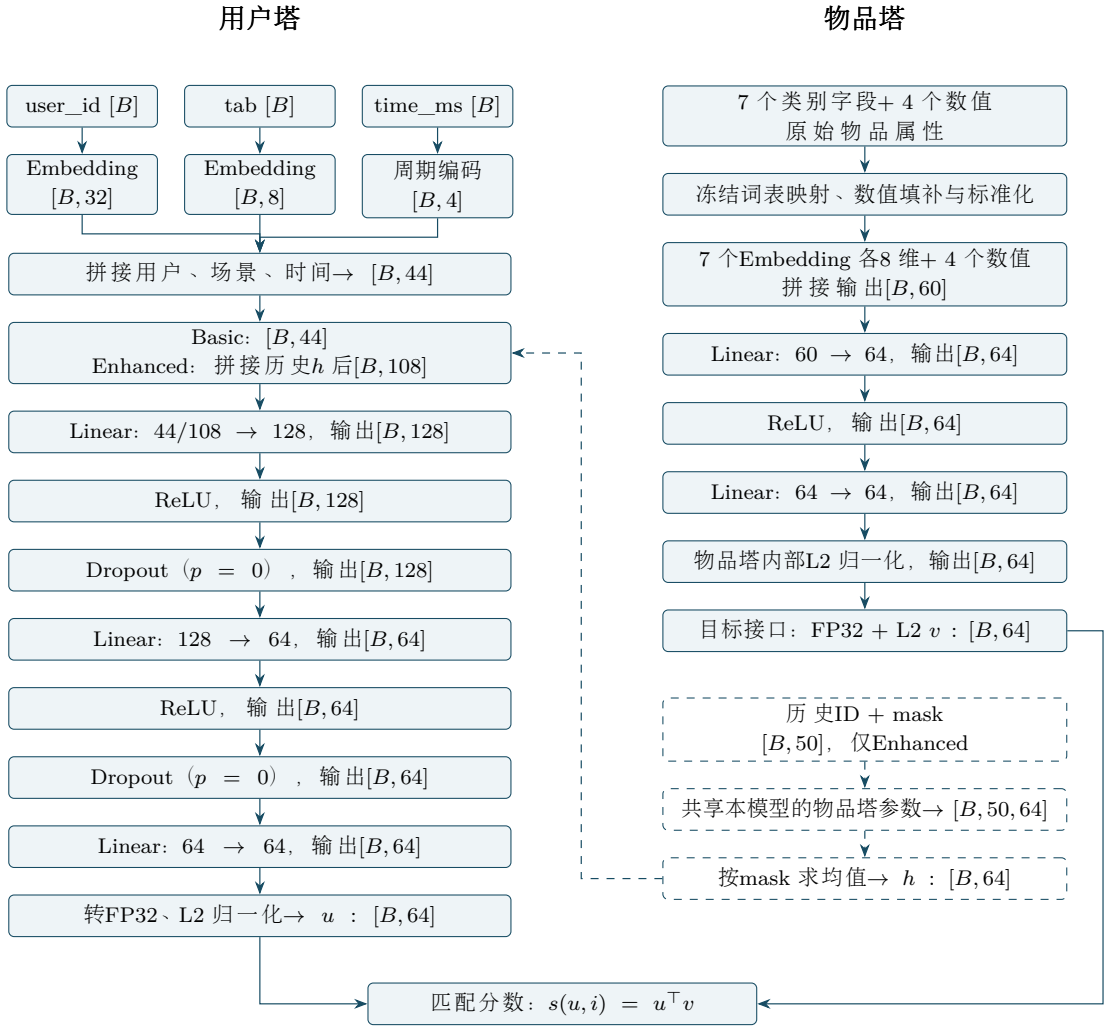


图 1: 按执行顺序逐层展开。Basic 与Enhanced 的物品特征及架构一致，但分别训练，权重不共享。虚线仅表示Enhanced 内部的历史分支与目标物品共用参数；B 为batch 大小。

用户塔有两次ReLU，分别位于两个隐藏Linear 后；末尾Linear 后直接归一化，没有额外ReLU。物品MLP 则是Linear、ReLU、Linear，随后归一化。Dropout 模块在代码中保留，但$p = 0$ 不改变输入；BN 关闭。目标物品统一接口的再次归一化是数值保护，不增加可训练层；历史路径直接复用物品塔。

L2 归一化：将向量除以其欧氏长度，即$\hat{z} = z/\sqrt{\sum_j z_j^2}$。例如$(3, 4)$ 的长度为5，归一化为$(0.6, 0.8)$。这样保留方向、统一长度；两条单位向量的点积就是余弦相似度，分数取决于方向匹配，而非向量大小。归一化不会增加内容信息。

语义边界：首标签、类型和发布属性提供有限内容线索，ID embedding 学习协同关联。模型尚未读取画面、音频、标题或字幕，音乐ID 也不是音频语义向量。当前弱效果不能归结为单一原因；后续通过消融检验内容与历史的收益。

3.2 监督信号与损失

监督信号的来源：直接沿用官方二元标签`long_view`，不重新生成标签。视频时长不超过18 秒时，观看达到视频时长为正反馈；时长超过18 秒时，观看达到18 秒为正反馈。正式训练仅保留训练窗口内`is_random=0` 且`long_view=1` 的记录。`is_random=0` 表示原推荐系统的常规曝光。

一条训练样本：请求q_i 包含当时的用户ID、场景、时间；Enhanced 另使用已可用历史；v_i 对应这条记录中用户实际长观看的视频。监督告诉模型“在这个请求下，这个视频是正目标”。当前不把`long_view=0` 的记录送入损失，也不使用点赞加权或观看时长回归。



图 2: 三个目标视频不同的batch 示例。矩阵单元是模型分数，蓝色对角线标记正确配对，并不是输入的标签值；同一用户可以产生多条请求。训练提高每行正目标相对于比较对象的分数。

用户塔把请求q_i 编码为u_i，物品塔编码batch 中所有目标视频；分数矩阵大小为$B \times B$，元素为$S_{ij} = u_i^\top v_j/\tau$，$\tau = 0.1$。请求和其实际视频按同一顺序排列，故正确配对恰好位于(i, i)，这就是**“对角线正目标”**。图中交叉熵的目标列索引为$[0, 1, 2]$；这些索引仅指batch 内位置，不是视频类别，也不是新的二元反馈标签。

若两个请求的目标是同一视频，定义$D_i = \{j \neq i : \text{item_id}(v_j) = \text{item_id}(v_i)\}$，屏蔽这些非对角重复位置，保留对角线。损失为

$$\mathcal{L} = -\frac{1}{B}\sum_{i=1}^{B} \log \frac{\exp(S_{ii})}{\sum_{j \notin D_i} \exp(S_{ij})}.$$

其余物品是批内采样的比较对象，**并非已知的用户负反馈**：另一个请求长观看的视频，不代表当前请求不喜欢它。当前没有采样频率修正，仍可能存在假负例。

矩阵对训练的启发：模型要学的是“这个请求与其实际长观看视频是否匹配”，因此每一行都以该请求的正目标为监督，而不是让所有请求都给同一热门视频最高分。用户塔与物品塔通过匹配分数共同获得梯度；请求与目标的顺序必须保持配对，否则对角线标签会指向错误视频。

非对角视频只是采样来的竞争对象，可能也是用户喜欢的视频；重复目标屏蔽只能避免同一视频被误当竞争对象，不能消除全部假负例。该损失只优化batch 内的相对分数，**loss 下降不保证在全部7,583 个候选中召回更好**，所以每个epoch 还需做完整候选检索评估，并据验证指标选择checkpoint。

4 训练配置、结果与恢复验证

4.1 冻结的公平比较配置

项目	设置	项目	设置
随机种子	42，同一打乱顺序	Batch / Epoch	256 / 1
优化器	Adam，$\beta = (0.9, 0.999)$	学习率	0.001
Weight decay	0	Temperature	0.1
Dropout / BN	0 / 关闭	输出维度	64，L2 归一化
设备	A100-SXM4-40GB，CUDA AMP	运行环境	Python 3.11.15；PyTorch 2.14.1+cu130

表 4: 两组使用相同数据、预算与优化设置；本次未进行超参数搜索。

4.2 训练诊断

模型	消费样本	更新步数	验证loss	Step+wait（秒）	峰值显存（MiB）
Basic	124,255	486	5.515324	8.077	85.92
Enhanced	124,255	486	5.503570	10.086	101.53

表 5: 耗时为日志中的读取等待与训练step 之和，不含完整验证、checkpoint 保存和编排；显存为PyTorch allocated 峰值。

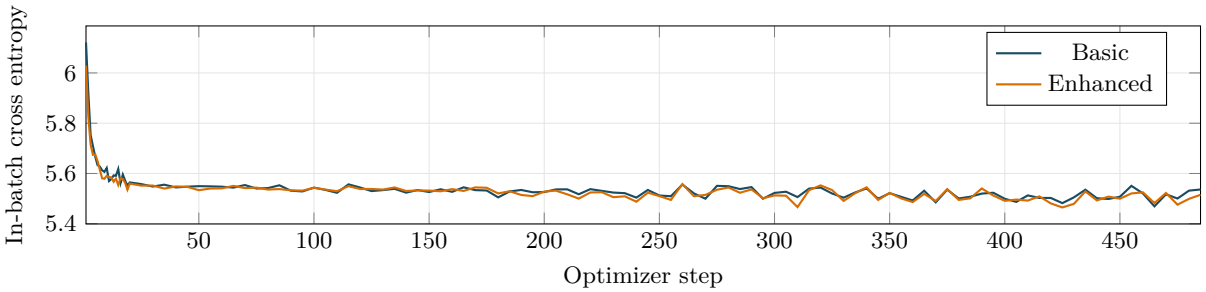


图 3: 实际训练loss；前20 步逐步展示，之后每5 步取一个日志点。只画完整batch，避免尾批造成误导。

尾批骤降的原因：前485 批各256 条，最后一批为95 条。均匀打分的参考交叉熵会由$\ln 256 = 5.545$ 降至$\ln 95 = 4.554$，并受重复目标屏蔽影响。实际尾批loss 为4.509（Basic）和4.488（Enhanced），不能当作突然学好了。

相同验证批次与重复屏蔽下，均匀打分参考loss 约为5.540678。两组验证loss 分别低于此值约0.025 与0.037，与较弱的召回效果一致；批内loss 稳定不等于全候选检索有效。

4.3 导出与恢复

两组各导出7,583 个归一化64 维物品向量，候选ID、维度、有限值、单位范数和checkpoint 绑定均通过检查。Enhanced 在第25 步保存，恢复后最终消费124,255 条样本、完成486 步。模型、Adam、AMP、随机状态与游标均与连续训练**完全一致**。

这验证了**同一环境中的受控保存与恢复**，尚未验证Colab 断线或重建runtime 后恢复。checkpoint 文件hash 不同可以来自运行元信息与序列化差异；验收比较的是训练状态。

5 评估协议与结果

5.1 每条请求如何判断命中?

一条验证请求的定义：从原始日志中取一条位于UTC 4 月29 日至5 月4 日前、`is_random=0` 且`long_view=1` 的观看记录，精确整行去重后，把它当成一次离线召回查询。共保留30,589 条，每条有独立请求ID；它不是一个用户汇总的观看清单，也不一定对应一次完整的线上页面刷新。

查询输入是这条记录的用户ID、场景和请求时间；Enhanced 还读取当时已可用的正反馈历史。这条记录实际长观看的视频是**唯一正目标**，只在生成推荐之后用于检查命中。一个用户的多次观看分别形成多条请求；重复观看同一视频也分别计数，只删除完全相同的原始行。

热门基线按**训练期内，经平台正常推荐产生的长观看次数**给视频排序，即只统计训练窗口的`is_random=0, long_view=1` 记录，不统计历史预热、验证期或随机曝光的观看。双塔按该请求用户向量与物品向量的点积排序。两者生成推荐时都不知道当前目标标签，使用相同候选库与资格规则；同分按原始视频ID 升序。允许推荐历史看过的视频，参数在验证期不更新。

热门排序是否因用户而异? 每个请求都会得到一个Top-100，但热门分数是一份全局物品计数，不读取用户ID 或历史。同一时刻、候选资格相同的用户会得到相同热门榜；不同时刻可能因视频上传资格变化而不同。本次全部候选在验证期均已合格，热门基线给所有验证请求的是同一份榜单。双塔则按各请求上下文重新计算分数，能够产生不同榜单。

分子：实际目标进入该请求Top-100 的请求数。 **分母：**全部30,589 条验证请求。 100 是每次推荐的数量，不是分母。同一用户多次观看分别评估，不合并视频去重。

令r_q 为第q 条请求的目标排名；未进入榜单或不具备候选资格时视为未命中:

$$\text{Recall@100} = \frac{\sum_{q=1}^{Q} \mathbf{1}[r_q \le 100]}{Q}, \qquad Q = 30,589.$$

$$\text{NDCG@100} = \frac{1}{Q} \sum_{q=1}^{Q} \frac{\mathbf{1}[r_q \le 100]}{\log_2(r_q + 1)}.$$

NDCG 的ground truth：每条请求只把该条日志中实际长观看的视频记为相关性1，其他候选在本次指标中记为0；这个0 不表示用户真实不喜欢它们。我们没有获得用户对所有视频的真实偏好排序，也不以热门次数生成ground truth。

理想排序只需把这个唯一正目标放在第1 位，其余视频顺序任意，因此IDCG@100 $= 1/\log_2(1+1) = 1$。模型把目标放在第r_q 位时，NDCG@100 $=$ DCG/IDCG $= 1/\log_2(r_q + 1)$；目标不在Top-100 或无法检索时记为0。例如目标排第2 位得$1/\log_2 3 \approx 0.631$，不是与一份完整的人工排序逐项比较。

Recall 只看是否进入前100；NDCG 同时看位置，排第1 得1 分，排第10 约得0.289 分，排第100 约得0.150 分。本指标按请求平均，活跃用户权重更大；尚未计算每个用户等权的平均命中率。

5.2 三组在同一协议上的比较

模型	命中请求数	Recall@100	NDCG@100	目标覆盖率
热门基线	**8,283**	**27.078%**	**0.069607**	100%
Basic 双塔	766	2.504%	0.007095	100%
Enhanced 双塔	692	2.262%	0.006145	100%

表 6: 已从逐请求预测独立复算命中数与NDCG，并核对冻结请求身份与产物版本。

三组每次均返回100 个不重复且符合资格的视频；目标覆盖率为100%，因此条件指标与端到端指标相同。热门计数只使用训练期标签，并未使用验证答案，不属于标签泄漏。

实验结论：热门明显领先两组双塔；Enhanced 少命中74 条请求，没有证明平均历史带来了收益。当前只有seed 42、1 epoch，不能把两组的小差异解释成稳定优势或劣势。验证来自原推荐策略的曝光，结果也不能直接等同线上收益。

6 成本、限制与下一周安排

6.1 评估成本与覆盖

用户编码在GPU，精确点积与排序在CPU。分块检索避免常驻完整请求× 候选矩阵。下表使用batch 256、排除1 个预热batch；包含特征组装、编码、必要的GPU 到CPU 传输与检索，不含初始模型和数据加载。

模型	用户编码（秒）	检索（秒）	Batch P50（秒）	Batch P95（秒）
热门	0.002480	13.434823	0.112512	0.114549
Basic	0.410511	26.051938	0.207814	0.287722
Enhanced	0.607318	25.615197	0.209800	0.259868

表 7: Colab 实测批量耗时，不是线上单请求延迟，也不是GPU 检索性能。

验证请求中未知用户1,213 条（3.965%），空历史456 条（1.491%）。训练词表未收录的物品ID 占候选库的9.244%，占验证正目标的0.111%；这些ID 使用未知embedding，但仍可由其余物品属性编码，并在合法候选库中，不等于目标缺失。

6.2 解释边界

Pure 删除池外观看，历史不完整；反馈完成时间和上传资格均依赖代理规则。发布属性没有可验证的历史版本，本次采用固定内容假设；时长已与日志核对，动态状态与未来统计仍被排除。只有一次短预算训练，未测多seed、用户等权指标或上线效果。批内比较可能包含假负例和采样偏差。**目前没有证据把弱效果归因于某一个代码错误或单一超参数。**

6.3 下一周优先任务

1. 完成KuaiRand-1K 数据的预处理，并将准备好的数据与版本说明放到共享Drive。
2. 设计基线与评估协议：比较常规／随机曝光的长观看次数与长观看率，处理低曝光样本；设计独立时间窗口的随机曝光评估，明确曝光偏差与解释范围。当前热门基线不代表效果上限。
3. 调整神经网络架构：尝试加深网络、残差连接（residual connection）、attention / LSTM，以及batch normalization。
4. 调整超参数，开展更多实验，并完整记录配置、训练过程与评估结果。
5. 每个epoch 都进行evaluation；根据验证集指标选择最佳checkpoint，用于后续部署（deploy）。

6.4 复现入口与依据

代码位于`research/kuairand/`。执行版本为`5626823`，Drive release 为`week1-pure-content-v1-001`。完整校验值和聚合结果见报告旁的`report_evidence.json` 与`evidence/content-v1/`；checkpoint、向量与逐请求数据留在私有Drive，不在正文堆叠长hash。

训练run：Basic `087cea6d74ef`；Enhanced `3e2c0f26ec9b`；恢复验收`0f6bc7c9effd`。恢复run 不是第三种模型。数据和模型使用既有流水线，未另建训练系统。

参考资料

[1] KuaiRand 官方数据版本与字段说明：https://kuairand.com/。

[2] Gao 等，KuaiRand，CIKM 2022：https://arxiv.org/abs/2208.08696。